

Régressions pénalisées et sélection de variables

Master 2 Économétrie et Statistique, parcours Économétrie Appliquée

UK Economy

Séries temporelles mensuelle UK de janvier 1998 à juin 2024

PALACIO BARCO Gloria Isabel

Directeur du master : **DARNE Olivier**

6 Nov 2024

Liste des abréviations

ACP : Analyse en Composantes Principales

ADF : Augmented Dickey-Fuller Test

AO : Additive Outliers

AR : Auto-Regressive

CLI : Composite Leading Indicator (Indice composite avancé)

COVID : Coronavirus Disease

CPI ALL : Consumer Price Index (All items)

CPIH : Consumer Price Index including Housing

EM : Expectation-Maximization

FTSE : Financial Times Stock Exchange Index

GBP_EUR : British Pound to Euro Exchange Rate

GBP_JAP : British Pound to Japanese Yen Exchange Rate

GBP_US : British Pound to US Dollar Exchange Rate

GETS : General-to-Specific

IOS : Indice des Services

IOP_MANU : Indice de Production Manufacturière

LASSO : Least Absolute Shrinkage and Selection Operator

LIBOR : London Interbank Offered Rate

M2 : Monetary Aggregate M2

RPI : Retail Price Index

SCAD : Smoothly Clipped Absolute Deviation

SIS : Sure Independence Screening

X-13-ARIMA-SEATS : Seasonal Adjustment Tool by ARIMA Modeling

Résumé

Ce projet analyse une base de données macroéconomiques mensuelles du Royaume-Uni pour modéliser l'inflation, représentée par l'indice CPI_ALL. Nous avons exploré divers modèles de régression pénalisée, notamment Ridge, LASSO, Elastic Net, SCAD et adaptive LASSO, avec et sans l'utilisation de la méthode de filtrage SIS. Nous avons également testé une approche économétrique de sélection par GETS et un modèle non linéaire avec le gradient boosting. L'ajout de décalages temporels a permis de capturer la dépendance entre les variables explicatives et la variable cible. Nos résultats montrent une forte sélectivité pour l'aLASSO, tandis que SCAD conserve davantage de variables, en particulier celles aux coefficients significatifs. Chaque méthode présente des spécificités, et bien que leur comparaison soit complexe, nous avons examiné le nombre de variables sélectionnées pour évaluer leurs différences.

Abstract

This project analyzes a monthly macroeconomic database from the United Kingdom to model inflation, represented by the CPI_ALL index. We explored various penalized regression models, including Ridge, LASSO, Elastic Net, SCAD, and adaptive LASSO, both with and without the SIS filtering method. Additionally, we tested a variable selection approach using GETS and a nonlinear model with gradient boosting. The inclusion of temporal lags allowed us to capture dependencies between explanatory variables and the target variable. Our results show high selectivity for aLASSO, while SCAD retains more variables, especially those with significant coefficients. Each method has unique characteristics, and despite the complexity of comparing them, we examined the number of selected variables to evaluate their differences.

Mots-clés : *Sélection de variables, stationnarité, régression pénalisée, inflation, CPI , Royaume-Uni, réduction de dimension*

1 Sommaire

1	SOMMAIRE	4
2	INTRODUCTION	1
3	ANALYSE EXPLORATOIRE ET DESCRIPTIVE	2
4	SELECTION DES VARIABLES	16
5	CONCLUSION.....	34
6	BIBLIOGRAPHIE.....	36
7	ANNEXE	37

2 Introduction

Comprendre les mécanismes qui influencent les prix est essentiel face aux transformations rapides de l'économie mondiale. L'indice des prix à la consommation, indicateur clé de l'inflation, reflète l'évolution moyenne des prix payés pour un panier de biens et services. Ce projet se concentre sur l'indice CPI ALL, couvrant l'ensemble des biens et services, et offrant une perspective globale des prix à la consommation. Avec une année de base en 2015, toute valeur différente de 100 indique une variation par rapport aux prix de cette année.

En analysant des données mensuelles de janvier 1998 à juillet 2024, nous nous intéressons au Royaume-Uni, un pays qui a traversé des événements économiques majeurs au cours de cette période. La crise financière de 2008, le référendum sur le Brexit en 2016 a engendré une incertitude politique et économique, influençant les taux de change et les relations commerciales avec l'Union européenne. Plus récemment, la pandémie de COVID-19 a provoqué des perturbations sans précédent, entraînant des confinements, une baisse de la production économique et des modifications significatives des habitudes de consommation. Par ailleurs, la crise énergétique due au conflit en Ukraine a entraîné une flambée des prix de l'énergie, impactant directement les coûts pour les consommateurs.

À l'ère du big data, la manipulation de grands ensembles de données présente des défis tels qu'une complexité computationnelle et le risque de surapprentissage. Les techniques de machine learning, tels que les régressions pénalisées, offrent des solutions robustes pour la sélection de variables et l'optimisation des modèles. Ces méthodes introduisent des termes de régularisation pour pénaliser la complexité du modèle, équilibrant efficacement le biais et la variance tout en améliorant la précision.

L'objectif de ce projet est d'appliquer des méthodes de régression pénalisée pour réduire le nombre de variables explicatives influençant l'indice CPI ALL. En procédant ainsi, nous visons à identifier les facteurs les plus significatifs affectant les prix à la consommation au Royaume-Uni.

3 Analyse exploratoire et descriptive

Le jeu de données utilisé pour ce projet est la « United Kingdom Monthly Database »¹ du mois d'août 2024. Il se compose de données macroéconomiques mensuelles pour le Royaume-Uni, s'étendant depuis janvier 1998.

L'ensemble de données contient 110 indicateurs mensuels, répartis en neuf grandes catégories qui couvrent l'essentiel des aspects macroéconomiques et financiers, facilitant ainsi une analyse complète du comportement de l'économie britannique dans différentes dimensions (prix, taux d'intérêt, production, sentiment économique, etc.)

3.1 Analyse des valeurs manquantes

Le descriptif fourni avec la base de données indique que les valeurs manquantes ont été remplacées à l'aide d'un algorithme EM (Expectation-Maximization). Cette approche permet d'éviter les biais associés aux données manquantes et facilite l'estimation des modèles, surtout compte tenu des différentes dates de début des indicateurs, qui s'étendent de 1960 à 2000.

Cependant, notre analyse des valeurs manquantes révèle la présence de 80 valeurs N/A. Parmi celles-ci, 62 sont observées pour le dernier mois, c'est-à-dire juillet 2024, ce qui signifie que plus de la moitié des données n'ont pas encore été incluses. Pareil pour le 2024-06-01 au total 15 N/A. Par conséquent, nous avons décidé de ne pas conserver le mois de juin et juillet 2024 dans notre analyse.

Nous avons également identifié 3 valeurs relatives à la variable LIBOR_3mth, qui représente le taux interbancaire offert à Londres (LIBOR) sur 3 mois. Les dates de ces valeurs sont : 2021-08-01, 2021-09-01 et 2024-05-01.

Nous procédons à l'imputation de ces données manquantes à l'aide du package *amelia*², qui met en œuvre l'algorithme EM mentionné précédemment. En maximisant la vraisemblance des paramètres, l'algorithme EM fournit des estimations plus robustes que les méthodes d'imputation simples.


¹ (Goulet Coulombe, 2021)

² (James Honaker, 2023)

3.2 Analyse des outliers : détection et correction

A l'aide du package *tsoutliers*, nous obtenons la Figure 1, qui permet d'observer les valeurs atypiques affectant notre série.

Figure 1 Outliers série à niveau CPI-ALL



Nous avons ainsi identifié trois valeurs atypiques dans notre série (Tableau 1), sous la forme d'outliers additifs (Additive Outliers, AO). Un AO correspond à une valeur anormale ponctuelle qui affecte temporairement la série sans modifier les valeurs des périodes suivantes.

Tableau 1 Détail des points atypiques

Type	Individu	Date	Impact
AO	272	2020:08	Négatif
AO	292	2022:04	Positif
AO	298	2022:10	Positif

Ainsi, en août 2020, l'économie du Royaume-Uni a été fortement impactée par la pandémie de COVID-19, avec un effet négatif lié à la faible demande et aux baisses de prix dans certains secteurs, conséquence des mesures de confinement.

En avril 2022, l'impact positif s'explique par une reprise économique marquée, accompagnée de pressions inflationnistes et d'une augmentation des prix des biens et services. Cette hausse peut être attribuée à des problèmes persistants dans les chaînes d'approvisionnement mondiales, ainsi qu'à une demande accrue après la levée des restrictions.


Enfin, en octobre 2022, l'impact positif peut être attribué à l'instabilité géopolitique liée à la guerre entre l'Ukraine et la Russie, qui a fortement perturbé les marchés de l'énergie et des matières premières, accentuant ainsi l'inflation.

Les principales contributions à cette hausse proviennent des augmentations de prix de l'électricité, du gaz, des combustibles, ainsi que des produits alimentaires, des boissons non alcoolisées et des transports (notamment les carburants).³

Ensuite, nous corrigeons ces outliers et obtenons une nouvelle série ajustée, avec laquelle nous poursuivons notre analyse.

La Figure 2 présente un comparatif entre l'ancienne série et la série ajustée, permettant de visualiser les effets de la correction.

Figure 2 Comparaison série en niveau et série ajustée



3.3 Analyse de la stationnarité de la variable à expliquer

Pour vérifier la stationnarité, nous avons appliqué le test de Dickey-Fuller Augmenté (ADF) à la série ajustée, obtenant une p-value de 0,2183. Comme cette valeur dépasse 0,05, nous ne pouvons pas rejeter l'hypothèse nulle, ce qui indique que la série reste non stationnaire.

En explorant le fichier ZIP récupéré, nous avons trouvé trois versions de données :

- raw_uk_md : les données brutes, démarrant en 1948
- tr_uk_md : les données transformées de UKMD.xlsx pour induire la stationnarité
- balanced_uk_md.xlsx : un panel stationnaire et équilibré commençant en janvier 1998, avec les valeurs manquantes remplacées via l'algorithme EM

Notre série ajustée provient du fichier "balanced_uk_md", dont la documentation indique que la stationnarité a été obtenue par une première différenciation logarithmique. Pour confirmer cela et mieux comprendre les transformations appliquées à notre variable

³ (Consumer price inflation, UK: October 2022, 2022)

d'intérêt, nous allons analyser les données brutes en appliquant les mêmes transformations afin de vérifier la stationnarité.

L'analyse de la série brute (voir Annexe 1) a révélé que la série n'était pas stationnaire, avec une p-value de 0,7186. Cependant, après application de la différenciation logarithmique, la série est devenue stationnaire, avec une p-value de 0,01427.

La comparaison graphique entre ces deux versions (voir Annexe 2) montre des différences, suggérant que d'autres transformations ont été appliquées à la série brute.

La documentation mentionne également que certaines séries ont été désaisonnalisées. Nous avons donc appliqué un ajustement saisonnier avec X-13-ARIMA-SEATS, ce qui a permis de retrouver la forme de notre série.

Ayant clarifié les transformations appliquées à notre série « CPI_ALL », nous décidons de poursuivre l'analyse avec la série du fichier "balanced", sans nouvelle différenciation.

3.4 Graphique de la variable à expliquer en niveau

Notre variable représente l'évolution générale des prix à la consommation pour l'ensemble des biens et services au Royaume-Uni. À la suite des transformations mentionnées précédemment, notre variable d'intérêt peut désormais être interprétée comme le taux de croissance du CPI ALL, c'est-à-dire une approximation du taux d'inflation périodique Figure 3 :

Figure 3 Graphique de la série à expliquer



3.5 Statistiques descriptives de la variable à expliquer

Nous nous intéressons maintenant aux statistiques descriptives de notre variable à expliquer, ce qui nous permettra de mieux la comprendre et d'observer ses caractéristiques. Le Tableau 2 présente les principales statistiques :


Tableau 2 Statistiques descriptives

CPI ALL	
Min.	-0.0012002
1st Qu	0.0009586
Median	0.0016377
Mean	0.0019447
3rd Qu	0.0025426
Max.	0.0079055
Skewness	1.239246
Kurtosis	2.115502
Variance	2.483173e-06

Notre série présente une valeur minimale de -0,0012002, ce qui indique des périodes de déflation où les prix ont légèrement diminué par rapport au mois précédent.

La médiane de 0,0016377 reflète une tendance centrale d'environ 0,16 % d'inflation mensuelle, ce qui signifie que 50 % des mois affichent un taux de croissance inférieur à cette valeur. La moyenne de 0,0019447, légèrement supérieure à la médiane, suggère une asymétrie positive dans la distribution des taux de croissance. En effet, cette différence entre la moyenne et la médiane est confirmée par une asymétrie (skewness) de 1,24, indiquant que la distribution est biaisée vers la droite (Figure 4). Cela signifie que, bien que la plupart des variations mensuelles soient modérées, certains mois présentent des taux de croissance plus élevés, créant une longue queue à droite dans la distribution.

Figure 4 Distribution série ajusté



La kurtosis de 2,12, inférieure à la valeur de référence de 3 pour une distribution normale, montre que notre série est plus plate que la normale. Cela signifie qu'il y a moins de valeurs extrêmes que ce que l'on observe dans une distribution normale, ce qui est cohérent avec le fait que nous avons corrigé les valeurs atypiques. Les fluctuations mensuelles restent donc principalement modérées, avec peu de variations extrêmes.

De plus, la variance très faible de $2,483173e-06$ montre que les variations mensuelles de notre série transformée sont globalement petites, indiquant une faible volatilité. Ce résultat, cohérent avec l'objectif de stationnarité visé par nos transformations, confirme que, malgré quelques pics occasionnels d'inflation, les fluctuations restent stables et modérées, rendant la série plus prévisible et moins sensible aux grandes variations.

Tableau 3 Shapiro-Wilk normality test

p value
4.175e-12

Enfin, le test de Shapiro-Wilk avec une p-value $< 0,05$ confirme une distribution non normale, en accord avec l'asymétrie et la kurtosis observées.

3.6 Classification


Dans cette partie, nous souhaitons identifier les structures sous-jacentes et les relations entre les variables explicatives, tout en facilitant la visualisation de groupes de données .

3.6.1 ACP

Pour commencer, nous effectuons une analyse en composantes principales (ACP), une méthode de réduction de dimensionnalité qui simplifie un grand nombre de variables en un ensemble plus restreint de composantes principales.

En appliquant la méthode du coude, nous retenons les trois premiers axes, qui représentent 31,75 % (Annexe 3) de la variance totale. Bien que cette proportion de variance puisse sembler faible, l'ajout d'axes supplémentaires n'apporterait plus de gain significatif en termes de variance expliquée. Retenir ces trois axes constitue donc le meilleur compromis pour obtenir une projection plus simple, sans sacrifier de manière excessive l'information globale contenue dans les données.

Figure 5 ACP



A partir de la Figure 5, nous pouvons observer que l'axe 1 représente la composante principale qui explique la plus grande part de la variance 18,76%. Les dix variables les plus contributives pour l'axe 1 (Annexe 4) capturent principalement des aspects liés au secteur des services, au commerce de détail, à la confiance des consommateurs et à la production manufacturière.

Les variables de type IOS (Indice des Services) et ses déclinaisons reflètent divers aspects du secteur des services, tels que le commerce de gros et de détail, l'éducation et les services non-distribution.

De plus, les variables « AVG WEEK RETAIL SALE NON FOOD » et « AVG WEEK RETAIL SALE » mesurent les ventes au détail hebdomadaires pour les biens non alimentaires et

l'ensemble des biens, respectivement. Ces indicateurs reflètent la consommation des ménages, un moteur principal de la demande globale et, par conséquent, de l'inflation.

Par ailleurs, l'indice composite avancé (CLI) mesure la confiance des consommateurs et constitue un indicateur précurseur de l'activité économique future. L'IOP_MANU (Indice de Production Manufacturière) reflète la production dans le secteur manufacturier, indiquant ainsi l'état de l'industrie et son influence sur les prix à la consommation.

L'axe 1 capture donc l'interaction entre la consommation des ménages, la production industrielle et la confiance économique.

L'axe 2 révèle des facteurs liés aux conditions monétaires, aux indices de prix alternatifs et aux coûts de financement. Les variables les plus contributives incluent des indices comme le RPI et le CPIH, qui fournissent des mesures alternatives de l'inflation, ainsi que des indicateurs monétaires comme le LIBOR, le Bank Rate, et les rendements des obligations d'État à 5 ans. Ces variables capturent les coûts d'emprunt et les attentes d'inflation, influençant directement la consommation et l'investissement des ménages et des entreprises.

Enfin, l'axe 3 de notre ACP se distingue par des variables liées aux marchés financiers, aux taux de change et à la masse monétaire. On trouve des indicateurs comme le « GBP_BROAD », qui mesure la valeur de la livre sterling par rapport à un panier de devises, ainsi que les taux de change spécifiques avec le dollar américain (GBP_US), le yen japonais (GBP_JAP) et l'euro (GBP_EUR). Les indices boursiers, tels que le FTSE 250, le FTSE ALL, l'iShares MSCI UK et le S&P 500, ainsi que la masse monétaire M2, indiquent un lien avec la liquidité globale, influençant la consommation et les pressions inflationnistes.

Ainsi, l'axe 3 met en évidence la dimension internationale et monétaire des variables explicatives.

3.6.2 Clustering hiérarchique

Ensuite, nous avons effectué un clustering hiérarchique en calculant une matrice de distance basée sur la corrélation entre les variables. Cela nous permet de mesurer la similarité entre les variables elles-mêmes. Plus la distance est petite, plus les variables sont similaires.

Le dendrogramme Figure 6 nous permet d'observer les variables en fonctions des clusters :

10

variables reflètent l'interaction entre l'emploi, la production économique et les marchés financiers.

Le cluster 2 englobe des variables liées à la durée du chômage, aux heures de travail hebdomadaires et aux revenus hebdomadaires moyens (AWE). Il inclut également des indicateurs de vacances dans divers secteurs (consommation, fabrication), des indices de production (produits manufacturiers, biens durables), ainsi que des indices de services (IOS). Les variables relatives au commerce de détail (RETAIL_TRADE_INDEX, ventes hebdomadaires) et aux applications de crédit sont également présentes.


Ce groupe met en lumière les dynamiques du marché du travail, les niveaux de revenus, la consommation des ménages et le commerce de détail.

Le troisième cluster rassemble des variables liées aux indices de prix à la consommation et aux prix à la production (CPI, RPI, PPI), ainsi qu'aux taux de change de la livre sterling (GBP_BROAD, GBP_US, GBP_EUR). Il inclut également des prix des matières premières (OIL_PRICE) et des taux d'intérêt (BANK_RATE, LIBOR_3mth). Les taux hypothécaires et les rendements des obligations d'État (BGS_5yrs_yld, etc.) sont également présents. Ce groupe reflète les facteurs macroéconomiques influençant directement l'inflation, tels que les politiques monétaires, les fluctuations des taux de change, et les prix des matières premières.

3.7 Corrélation entre variables explicatives

Après avoir attribué chaque variable à un cluster spécifique, nous pouvons visualiser les corrélations entre les variables au sein de chaque cluster. Cela permet de mieux comprendre les relations internes spécifiques à chaque groupe de variables :

Figure 7 Corrélation cluster 1 et 2




Le cluster 1 (Figure 7 - gauche) montre des corrélations marquées, comme entre le nombre d'emplois et le taux d'emploi (0,89), ou entre l'activité économique et son taux (0,92), ce qui souligne une forte interdépendance des niveaux d'emploi et d'activité. De même, le nombre de demandes de chômage et leur taux (0,95) révèlent une sensibilité des aides sociales aux fluctuations de l'emploi. On observe également une corrélation quasi parfaite entre la production minière et l'extraction de pétrole (0,99).

Les importations et exportations totales sont très corrélées aux biens, illustrant leur poids dans les échanges commerciaux du Royaume-Uni, tandis que les importations de carburants et de pétrole montrent aussi une forte interdépendance. Enfin, les indices boursiers britanniques (FTSE) et internationaux (SP500) révèlent l'intégration des marchés financiers, avec des corrélations (0.83) indiquant une sensibilité aux tendances globales qui influencent directement l'économie britannique.

Concernant le cluster 2 nous observons de fortes corrélations aussi entre les heures de travail hebdomadaires, avec une corrélation de 0,97 entre TOT_WEEK_HRS et AVG_WEEK_HRS, et de 0,96 entre TOT_WEEK_HRS et AVG_WEEK_HRS_FULL, ce qui est cohérent dans les mesures d'activité de l'emploi.

Dans le secteur de la production, les indices industriels montrent des liens étroits, notamment entre IOP_PROD et IOP_MANU (0,96), ainsi que IOP_GOOD et IOP_NON_DUR (0,9), mettant en évidence une interdépendance dans la production de biens intermédiaires et durables. Les indices des services et du commerce de détail révèlent aussi des corrélations fortes, comme IOS_47 et RETAIL_TRADE_INDEX` (0,91), et entre RSI et AVG_WEEK_RETAIL_SALE (0,97), illustrant le lien entre les ventes au détail et la demande des ménages. Enfin, les corrélations entre les applications de crédit TOT_LENDING_APP et TOT_HOUSE_APP (0,89) reflètent la dynamique du secteur immobilier.

Figure 8 Corrélation cluster 3



Dans le Cluster 3 (Figure 8), on observe de fortes corrélations entre notre variable d'intérêt et d'autres indices de prix comme CPIH_ALL (0,82) et CPI_GOOD (0,89), ce qui indique que plusieurs variables capturent des aspects similaires de l'inflation. De même, les taux de change (GBP_BROAD et GBP_EUR, 0,87) et les rendements obligataires à différents horizons (BGS_5yrs_yld, BGS_10yrs_yld, et BGS_20yrs_yld) montrent des interdépendances significatives, reflétant des dynamiques communes dans les marchés financiers.

Ces fortes corrélations dans nos clusters révèlent un risque de multicollinéarité dans les régressions classiques, où la redondance entre variables pourrait entraîner une instabilité des coefficients.

3.8 Corrélation entre les variables explicative et la variable à expliquer


L'analyse des corrélations entre les variables explicatives et notre variable d'intérêt, nous aide à identifier les facteurs les plus étroitement liés à l'inflation. En distinguant les corrélations positives et négatives, nous comprenons mieux les relations synchrones et inverses entre les variables explicatives et CPI_ALL.

Les corrélations positives Figure 9 montrent les variables évoluant dans le même sens que CPI_ALL, ce qui signifie qu'elles augmentent lorsque l'inflation augmente, et inversement. Cela est particulièrement pertinent pour les indices de prix alternatifs tels que CPIH_ALL (0,85) et CPI_GOOD (0,81), qui présentent des tendances très proches de CPI_ALL. Cette cohérence est attendue, car ces indices mesurent également des aspects de l'inflation et incluent des éléments de la consommation.

Des indices comme CPI_DUR (0,42) et CPI_TRANS (0,47) présentent aussi des corrélations positives notables avec CPI_ALL, indiquant que les prix des biens durables et des transports suivent de près la tendance générale de l'inflation. Enfin, RPI_ALL (0,75), un autre indice de prix utilisé au Royaume-Uni, est également aligné avec CPI_ALL, ce qui montre que ces mesures d'inflation partagent des schémas similaires malgré des méthodes de calcul légèrement différentes.

D'un autre côté les corrélations négatives les plus fortes (Annexe 5) montrent des évolutions inverses entre l'inflation et certaines variables financières et économiques. La variable CONS_CREDIT_ex_student_loan (-0,29) indique qu'une hausse de l'inflation est associée à une baisse des crédits à la consommation, ce qui pourrait refléter une contraction des prêts en période de hausse des prix. De même, M1 (-0,25) montre une corrélation inverse notable, suggérant que l'augmentation de l'inflation pourrait être liée à une réduction de la masse monétaire. Enfin, les indices du commerce de détail (RETAIL_TRADE_INDEX à -0,13) et des ventes au détail (RSI à -0,13) sont aussi en corrélation négative avec CPI_ALL, signalant qu'une inflation élevée peut freiner les dépenses de consommation.

Figure 9 Corrélations positives avec CPI ALL



4 Sélection des variables

Dans cette deuxième section, nous procédons au prétraitement des données en vue de la sélection des variables.

Nous appliquons d'abord des retards (lags) pour examiner l'influence des valeurs passées sur la variable d'intérêt. Un retard d'une période est ainsi ajouté pour chaque variable explicative, tandis que la variable cible se voit attribuer quatre retards, permettant de capturer des relations temporelles significatives.

Ensuite, nous centrons et standardisons les données. En ramenant chaque variable à une moyenne de zéro et un écart-type d'un, nous réduisons l'impact de l'amplitude des variables, améliorant ainsi la comparabilité des coefficients dans les régressions pénalisées. Ces transformations évitent les problèmes d'échelle des variables lors de l'estimation des paramètres, rendant ainsi la sélection de variables plus stable et fiable. ⁴

4.1 Approche économétrique : GETS

L'approche GETS est une méthode économétrique qui vise à simplifier un modèle en partant d'une spécification large, puis en éliminant progressivement les variables non significatives pour arriver à un modèle parcimonieux.

Dans notre cas, avec les variables retardées, nous avons un total de 225 prédicteurs, ce qui donne un rapport p (variables) $\approx N$ (observations). Pour que la méthode GETS fonctionne correctement, le package *gets* nécessite que le nombre de prédicteurs soit inférieur au nombre d'observations ($p < N$). Bien que dans notre situation, ce critère soit respecté, le ratio p/N est très proche de 1, ce qui limite la capacité du modèle à sélectionner les variables avec précision.

En effet, lorsque le nombre de prédicteurs approche ou dépasse 89, la méthode GETS devient moins applicable, car elle rencontre des limitations techniques liées à la complexité du modèle et à la gestion de la dimensionnalité. ⁵

⁴ (Machine Learning, Régressions Pénalisées et Sélection de Variables, 2024)

⁵ (Techniques de Prévision et Conjoncture, 2024)

Pour pallier ces limitations, la régression pénalisée, qui impose une régularisation dans la sélection des variables, constitue une alternative plus efficace lorsque le nombre de prédicteurs est élevé.

4.2 Régressions pénalisées : Ridge, Lasso, Elastic-Net, SCAD et Adaptive Lasso

4.2.1 Lasso

La première méthode de régularisations que nous utilisons c'est la régression Lasso (Least Absolute Shrinkage and Selection Operator) qui impose une pénalisation sur les coefficients du modèle, ce qui favorise la sélection des variables les plus pertinentes en réduisant les coefficients de certaines variables à zéro. Cette approche est utile lorsque le nombre de prédicteurs est élevé, car elle permet de réduire la complexité du modèle tout en conservant les variables explicatives les plus importantes.

La sélection du paramètre de pénalisation (λ) par validation croisée permet de minimiser le risque de surajustement et d'optimiser le modèle.

Avec *lambda min* à 0.0343, le modèle conserve 23 variables, maximisant la précision en réduisant l'erreur (Annexe 6). En revanche, *lambda 1se* à 0.0722 limite le modèle à 11 variables, offrant ainsi une solution plus simple tout en maintenant une performance acceptable.

Tableau 4 Résultat méthode LASSO

Λ	N° variables
0.0722	11

Le Tableau 4 nous montre donc la valeur optimale de λ , qui garantit un bon compromis entre complexité et précision.

Au final, notre modèle Lasso a retenu 11 variables, ce qui constitue une réduction significative par rapport aux 224 variables initiales.

Les variables sélectionnées incluent principalement des indices de prix, tels que CPIH_ALL et CPI_GOOD, qui représentent des composantes importantes de l'inflation et des prix des biens. La durée du chômage de longue durée et l'indice des prix à la

production pour les produits manufacturés sont également inclus, ce qui reflète l'influence potentielle des coûts de production et de certaines composantes économiques sur l'inflation.

Les retards de CPI_ALL eux-mêmes ont été conservés, indiquant une forte autocorrélation dans les données d'inflation, où les valeurs passées aident à prédire les valeurs futures (voir Annexe 7)

Limites :

Cependant la régression Lasso peut rencontrer des problèmes dans notre étude en raison de la forte multicolinéarité entre certaines variables explicatives, comme nous l'avons observé dans les clusters de corrélation, où des groupes de variables reliées à l'emploi, aux prix et aux indices économiques présentent des relations étroites ; en sélectionnant uniquement une variable parmi un groupe corrélé, Lasso risque d'ignorer des facteurs pertinents pour comprendre l'inflation. Par ailleurs, Lasso peut pénaliser excessivement des variables aux effets faibles mais cumulativement significatifs, risquant ainsi d'écarter des informations importantes dans notre analyse.

4.2.2 Ridge

La régression Ridge est une méthode de régularisation particulièrement adaptée lorsque les prédictors sont multicolinéaires, comme c'est le cas dans notre étude où de nombreuses variables sont fortement corrélées.

Contrairement au Lasso, Ridge ne réalise pas de sélection de variables mais réduit la taille des coefficients en ajoutant une pénalité proportionnelle à la somme des carrés des coefficients (paramètre $\alpha = 0$). Cela permet de limiter les problèmes liés aux effets redondants tout en conservant l'information apportée par chaque variable.

Tableau 5 Résultat méthode Ridge

Λ	N° variables
0.3853	224

Le modèle Ridge utilise donc un λ plus élevé (Tableau 5) comparé à celui de LASSO, c'est qui est attendu, car il pénalise tous les coefficients en fonction de leur carré (régression par norme L2).

L'objectif de Ridge est de réduire la variance des coefficients sans les forcer à devenir exactement nuls, ce qui se traduit par une pénalisation plus forte pour stabiliser les coefficients, particulièrement en présence de multicollinéarité entre les prédicteurs.

Limites

Dans notre étude, la régression Ridge présente certaines limites en raison de son incapacité à sélectionner les variables, car cela peut introduire du bruit et compliquer l'interprétation des résultats. En revanche, Lasso permet la sélection de variables en forçant certains coefficients à zéro, mais il peut ignorer des groupes de variables corrélées, ne conservant qu'une seule variable par groupe, ce qui risque de faire perdre des informations pertinentes dans un contexte économique.

En réponse à ces limitations, nous passons maintenant à la méthode Elastic Net, qui combine les avantages de Lasso et de Ridge pour surmonter ces défis.

4.2.3 Elastic Net

Cette approche est adaptée à notre analyse, car elle est efficace lorsque des variables explicatives sont fortement corrélées, car elle pénalise les coefficients en fonction d'une combinaison des normes L1 (Lasso) et L2 (Ridge).

En ajustant le paramètre α , Elastic Net permet de moduler la proportion de chaque type de pénalisation, offrant ainsi un modèle qui conserve les avantages de sélection de variables de Lasso et de la réduction de la variance de Ridge.

Nous appliquons trois approches : tout d'abord, un α fixé à 0.5, qui applique de manière égale les pénalisations Lasso et Ridge. Ensuite, une recherche en grille (grid search) permet de sélectionner le meilleur α entre 0 et 1, en testant des valeurs par pas de 0.1, afin de trouver la combinaison optimale d' α et de λ minimisant l'erreur de validation croisée (cvm) et offrant un équilibre ajusté entre Lasso et Ridge.

Enfin, nous utilisons le package *caret* pour optimiser directement les hyperparamètres de notre modèle Elastic Net.

Les résultats obtenus à partir de ces trois approches sont les suivants :

Tableau 6 Résultat méthode Elastic Net

Approche	Λ	N° variables
α (0,5)	0.1519	11
Grid search α (0,3)	0.2205	15
Caret α (0,8)	0.01963	51

L'approche Elastic Net à $\alpha = 0.5$, les variables sélectionnées sont principalement liées aux indices de prix et aux facteurs macroéconomiques (Annexe 7).

Le résultat est identique à celui obtenu avec la méthode Lasso, car avec $\alpha = 0.5$, les pénalisations L1 (Lasso) et L2 (Ridge) sont appliquées de manière équilibrée, permettant à Lasso de jouer son rôle de sélection de variables sans que Ridge ne modifie significativement cette sélection. La régularisation L2 n'a donc pas introduit de changement dans les variables retenues, suggérant que la stabilité des coefficients était déjà assurée sans l'apport de Ridge.

Avec l'approche Grid Search, l' α optimal est de 0,3. Cette valeur est obtenue en testant différents niveaux d' α afin de minimiser l'erreur de validation croisée, permettant ainsi de trouver le meilleur équilibre entre les deux types de régularisation. Un α plus faible que dans l'approche précédente montre que le modèle s'appuie davantage sur Ridge pour gérer la multicolinéarité.

Le λ optimal trouvé est de 0,2205, imposant une pénalisation plus forte que celle de la première approche (0,1519) et sélectionnant 15 variables au lieu de 11. Parmi elles, on retrouve à nouveau des indices de prix, des indicateurs économiques et des mesures du marché de l'emploi.

Avec la troisième approche, nous avons défini une grille de tuning pour les hyperparamètres α et λ , car *caret* utilise une grille par défaut pour le modèle qui peut ne pas inclure toutes les valeurs d' α , notamment celles inférieures à 1.

Après l'entraînement, nous avons identifié un α optimal de 0.8 et un λ de 0.01963 (Tableau 6).

Avec ces paramètres, le modèle final a retenu 51 variables. Le faible lambda applique une régularisation légère, offrant ainsi au modèle une souplesse pour inclure davantage de variables sans imposer une pénalisation excessive. Cela permet au modèle d'intégrer une grande diversité de facteurs macroéconomiques et temporels.

Nous n'avons pas généré de graphique montrant la variation des coefficients en fonction de lambda, car *caret* avait déjà effectué une validation croisée optimisée des hyperparamètres, rendant ce graphique redondant. Par ailleurs, le lambda optimal trouvé peut ne pas correspondre exactement à l'un des lambdas testés dans *cv.glmnet*, ce qui pourrait générer une différence dans le nombre de variables sélectionnées.

4.2.4 SCAD

Nous allons maintenant aborder une autre forme de régression avec pénalités, les pénalités concaves, qui se distinguent des pénalités convexes par leur capacité à modérer la contrainte exercée sur les coefficients. Contrairement aux méthodes convexes comme Lasso, les pénalités concaves appliquent une régularisation qui s'adoucit pour les coefficients de grande valeur, offrant un meilleur compromis entre sélection de variables et précision des estimations.

Parmi ces méthodes, la SCAD (Smoothly Clipped Absolute Deviation) permet de sélectionner les variables tout en limitant les biais que peut introduire la pénalité Lasso. SCAD applique une pénalité qui diminue progressivement, permettant ainsi de conserver les variables pertinentes sans contraindre excessivement les coefficients proches de zéro.

Tableau 7 Résultat méthode SCAD

Λ	N° variables
0.02018	27

La méthode SCAD a trouvé un lambda optimal de 0.02018, une valeur relativement faible, ce qui est cohérent avec la sélection de 27 variables (Tableau 7). Cela signifie que le modèle a trouvé un niveau de régularisation suffisamment modéré pour conserver les variables importantes, tout en éliminant celles qui sont moins pertinentes.

En comparaison, l'approche LASSO impose une stricte pénalité L1, qui a tendance à sélectionner un plus petit nombre de variables (dans notre cas 11). Cette pénalité agit de manière uniforme sur tous les coefficients, en forçant même les petits coefficients à se rapprocher de zéro, ce qui réduit le nombre de variables retenues. En revanche, SCAD applique une pénalisation qui diminue progressivement pour les variables qui semblent plus importantes, permettant ainsi de conserver davantage de variables dans le modèle.

4.2.5 Adaptive Lasso

Nous allons maintenant aborder l'Adaptive Lasso, une méthode qui vise à corriger certains inconvénients des approches Lasso et SCAD.

Comme nous l'avons déjà évoqué, la méthode LASSO est efficace pour la sélection de variables, mais sa pénalité uniforme peut introduire un biais important sur les coefficients des variables influentes. La méthode SCAD, avec sa pénalité concave, corrige ce biais en appliquant une régularisation plus douce pour les coefficients importants, cependant, elle présente un inconvénient majeur : sa non-convexité, qui rend l'optimisation plus difficile en raison du risque de tomber dans des minima locaux.

L'adaptive Lasso propose une solution intermédiaire : il utilise la même pénalité L1 que le Lasso, mais introduit un paramètre de pondération qui adapte la pénalité en fonction de l'importance de chaque coefficient. Ces poids sont déterminés par une première estimation des coefficients via un modèle préliminaire, qui peut être Lasso, Ridge ou même une régression OLS. Dans notre cas, nous utiliserons Ridge pour déterminer ces poids.

Ainsi, l'aLasso combine les forces de Lasso en matière de sélection de variables, tout en corrigeant le biais sur les coefficients importants grâce à sa pénalisation adaptative. Cela permet de conserver la convexité de la régularisation (facilitant l'optimisation) tout en favorisant des estimations plus précises et une meilleure interprétation des coefficients.

Tableau 8 Résultat méthode aLASSO

Λ	N° variables
0.2212	6

Avec un λ optimal de 0.2213 pour l'aLASSO, le modèle a sélectionné 6 variables (Tableau 8). Cette sélection indique que, malgré une régularisation modérée, la pénalisation adaptative a permis d'éliminer les variables moins pertinentes tout en ajustant le biais des coefficients retenus pour obtenir des estimations plus fiables et interprétables.

Il est important de noter que le graphique de sélection de variables en fonction de λ (Annexe 7 - aLASSO) montre une plage plus importante de variables que le nombre final retenu. Cela s'explique par la pondération adaptative propre à l'Adaptive Lasso, où chaque variable reçoit un poids spécifique basé sur une estimation préliminaire (ici, une régression Ridge). Ces poids ajustent la force de la pénalité appliquée à chaque variable, rendant l'effet de la régularisation non uniforme. Ainsi, certaines variables avec de faibles poids restent actives à des valeurs de λ plus élevées, ce qui donne l'impression d'une sélection plus large dans le graphique.

4.3 Approche de réduction de dimension

L'approche SIS (*Sure Independence Screening*) est conçue pour réduire la dimensionnalité en ne conservant que les variables les plus corrélées avec la variable cible. Cette méthode permet de filtrer les variables de manière préliminaire, en identifiant celles qui sont potentiellement les plus informatives, et ainsi d'éliminer un grand nombre de variables non pertinentes avant d'appliquer des modèles de régression plus complexes.

Dans notre cas, nous n'appliquerons pas de pénalité dans l'étape de filtrage avec SIS, car l'objectif est simplement de réduire le nombre de variables pour sélectionner un sous-ensemble pertinent. Par la suite, nous pourrions appliquer des modèles de régression pénalisée, comme Ridge, Lasso, Adaptive Lasso (aLasso) ou SCAD, sur ce sous-ensemble réduit de variables.

Un total de 149 variables a été sélectionné par l'approche SIS pour l'analyse (Annexe 8)

4.3.1 GETS

Nous avons testé l'approche GETS en utilisant les variables pré-sélectionnées par SIS. Avant d'estimer le modèle, nous avons effectué un test de Durbin-Watson pour détecter

une éventuelle autocorrélation des résidus. La p-value supérieure à 0.05 indique que les résidus n'ont pas d'autocorrélation significative, rendant un terme autorégressif inutile. Cette absence d'autocorrélation peut s'expliquer par l'ajout de variables retardées, qui contribue à stabiliser les résidus en capturant les effets temporels.

L'application de l'approche GETS sur les variables sélectionnées par SIS a permis de simplifier le modèle tout en maintenant un ajustement élevé, avec un R^2 de 96.4%. Cela indique que le modèle réduit capture l'essentiel de la variance de la variable cible sans perte significative de précision. Bien que l'objectif soit ici la sélection de variables, les diagnostics confirment l'absence d'autocorrélation résiduelle et une stabilité des erreurs, comme le montrent les p-values élevées des tests de Ljung-Box.

Cependant, ce R^2 élevé doit être interprété avec prudence, car les données n'ont pas été divisées en ensembles d'entraînement et de test, et aucune validation croisée n'a été réalisée. Cela introduit un risque de surajustement : le modèle peut sembler très performant sur l'ensemble des données disponibles, mais risque de perdre en précision sur de nouvelles données. Une validation croisée ou une division des données aurait permis de mieux évaluer la robustesse du modèle, mais cela aurait été coûteux en temps et en ressources, notamment pour tester toutes les combinaisons de variables avec GETS sur plusieurs itérations.

En résumé, l'approche GETS, appliquée aux variables réduites par SIS, a permis de retenir 49 variables pertinentes sur les 149 initiales (Annexe 9). Cette réduction du nombre de prédicteurs améliore l'interprétabilité du modèle et le rend plus efficace.

4.3.2 Régressions pénalisées - SCAD

Nous allons maintenant appliquer les régressions pénalisées, comme précédemment, en utilisant les variables sélectionnées par SIS. Les méthodes incluront SCAD, LASSO, Elastic Net (avec les trois approches : alpha 0.5, grid search, et avec le package caret), RIDGE, ainsi que l'Adaptive Lasso (aLasso).

Car, bien que SIS ait déjà réduit le nombre de variables, les régressions pénalisées peuvent ajuster les coefficients en fonction de l'importance de chaque variable, améliorant ainsi la

stabilité des estimations et gérant la multicollinéarité. Cette approche nous permet d'obtenir un modèle plus simple, précis et basé sur les prédicteurs les plus informatifs.

En appliquant SCAD, nous pouvons observer que la dynamique de la régularisation a été modifié :

Tableau 9 Résultat SCAD avec SIS

Λ	N° variables
0.02164	44

Avec ce nouveau jeu de données, le modèle SCAD utilise un lambda légèrement plus élevé (0,02164) et sélectionne un nombre plus important de variables, soit 44 (Tableau 9), par rapport aux 27 retenues sans SIS (Tableau 7). Cette augmentation du nombre de prédicteurs peut être attribuée au fait qu'en appliquant SCAD après SIS, le modèle traite un sous-ensemble de variables déjà pré-filtrées, qui sont davantage pertinentes et susceptibles d'avoir des coefficients importants. Avec cette configuration, même un lambda plus élevé ne conduit pas forcément à une réduction du nombre de variables, car SCAD est conçu pour pénaliser moins sévèrement les grands coefficients, ce qui les rend plus susceptibles de rester dans le modèle final. En somme, l'approche combinée SIS-SCAD favorise la rétention de variables avec des relations significatives, même sous une régularisation renforcée, optimisant la pertinence et affine la modélisation.

4.3.3 LASSO

Le lambda optimal obtenu est de 0.0722 (Tableau 10), identique à celui trouvé sans SIS, tout comme le nombre de variables retenues.

Tableau 10 Résultat méthode LASSO avec SIS

Λ	N° variables
0.0722	11

Cela peut s'expliquer par le fait que le Lasso ajuste les coefficients en fonction de la pénalité lambda, qui dépend de la structure et des corrélations des variables avec la cible. Si les variables présélectionnées par SIS sont les plus fortement corrélées avec la cible, leur inclusion peut ne pas modifier de manière significative la valeur optimale de lambda.

Ainsi, même après le filtrage de SIS, le modèle retrouve une structure de régularisation similaire, expliquant pourquoi le lambda optimal reste le même.

4.3.4 Elastic Net

La méthode Elastic Net après SIS par différentes approches nous obtenons les résultats suivants :

Tableau 11 Résultats méthodes Elastic Net avec SIS

Approche	Λ	N° variables
α (0,5)	0.1519	11
Grid search α (0,3)	0.2205	15
Caret α (1)	0.0196	49

Nous obtenons les mêmes résultats avec et sans la présélection SIS dans l'approche Elastic Net ($\alpha = 0.5$), ainsi qu'avec l'approche par grid search. Cela indique que les variables sélectionnées par SIS sont effectivement les plus corrélées avec la cible, et Elastic Net les privilégie naturellement. Cette convergence conduit à une régularisation identique, avec le même lambda optimal et les mêmes variables retenues.

Cependant, l'utilisation de SIS a tout de même influencé l'approche avec le package *caret*, modifiant le lambda optimal, qui est passé de 0.01963 sans SIS à 0.01353 avec SIS. L'alpha optimal reste à 1, ce qui montre que le modèle se comporte principalement comme un LASSO, en privilégiant une sélection des variables. Grâce à SIS, le modèle retient 49 variables au lieu de 51 sans présélection, ce qui reflète une légère optimisation dans le choix des prédictors pertinents après filtrage.

4.3.5 RIDGE

Comme précédemment, nous avons utilisé la méthode Ridge pour ajuster le modèle, cette fois en appliquant la présélection des variables par SIS :

Tableau 12 Résultat méthode RIDGE avec SIS

Λ	N° variables
0.2205	149

Le lambda optimal est passé de 0.3853 sans SIS à 0.2205 avec SIS (Tableau 12), reflétant une réduction de la pénalisation nécessaire. Cette baisse du lambda s'explique par le fait que la présélection SIS a déjà éliminé des variables moins corrélées avec la cible, réduisant ainsi le besoin de régularisation pour limiter le bruit dans le modèle. Contrairement aux méthodes de type Lasso ou Elastic Net, Ridge ne fait pas de sélection de variables, et donc les 149 variables retenues par SIS sont toutes conservées dans le modèle final.

4.3.6 aLASSO

Et en fin, nous appliquons la méthode adaptive Lasso (aLASSO) avec les variables présélectionnées par SIS.

Tableau 13 Résultats méthodes aLASSO avec SIS

Λ	N° variables
0.2110	7

Le lambda optimal a légèrement diminué, passant de 0.2212 sans SIS à 0.2110 avec SIS, ce qui indique une régularisation un peu plus faible lorsque le modèle est appliqué aux variables filtrées.

La différence de variables sélectionnées est minime : sans SIS, 6 variables ont été retenues, tandis qu'avec SIS, le modèle en a conservé 7. La variable supplémentaire est CPI_ALL_lag4, qui semble apporter une information additionnelle dans le contexte des variables préalablement filtrées par SIS.

4.4 Méthode non linéaire – Gradient boosting

Après avoir exploré des méthodes de régression pénalisées comme le Lasso, SCAD et Elastic Net, etc. Nous passons à une approche non linéaire avec le gradient boosting pour la sélection de variables.

Bien que le gradient boosting n'ait pas de paramètres de pénalité explicites comme lambda ou alpha, des paramètres tels que le shrinkage (taux d'apprentissage), la profondeur d'interaction (profondeur des arbres) et le nombre d'arbres jouent un rôle similaire en contrôlant la complexité du modèle et en évitant le surapprentissage.⁶

⁶ (ARBRES DE DECISION et MÉTHODES D'ENSEMBLES (Random Forests, gradient boosting), 2024)

Nous commençons par tester différentes valeurs de shrinkage (0.1, 0.05, 0.01, 0.001) pour évaluer leurs effets sur les performances du modèle avec les variables sélectionnées par SIS. En ajustant les modèles et en analysant l'erreur de validation croisée, nous identifions le shrinkage optimal qui minimise l'erreur de prédiction.

Une fois ce shrinkage optimal (0.1) déterminé, nous évaluons l'impact de la profondeur d'interaction (de 1 à 5) pour comprendre comment la complexité des arbres affecte le modèle (voir Annexe 12 Choix des paramètres Gradient boosting). Nous sélectionnons la profondeur qui équilibre le mieux biais et variance. Enfin, la fonction *gbm.perf* nous permet de déterminer le nombre optimal d'arbres, assurant un bon niveau de complexité sans surapprentissage, comme nous le présente la Figure 10 :

Figure 10 Nombre d'arbres optimal




Tableau 14 Paramètres choisis Gradient boosting avec SIS

	Avec SIS	Sans SIS
Shrinkage	0.1	0.1
Profondeur	3	3
N° d'arbres	82	89
Variables retenues	89	116

Avec les paramètres retenus du Tableau 14, nous ajustons ensuite le modèle final et extrayons les scores d'importance des variables. En sélectionnant celles dont l'importance relative est supérieure à zéro, nous identifions les prédicteurs les plus significatifs selon l'algorithme de gradient boosting. Cette approche permet une sélection de variables, même sans paramètres de pénalité explicites. Au total, 89 variables ont été retenues parmi les 149 initiales (Annexe 13).

Nous avons aussi appliqué le gradient de boosting à l'ensemble de nos données, donc les 224 variables explicatives et les résultats pour le shrinkage et la profondeur sont les mêmes que pour les variables sélectionnées avec SIS. Cependant, on observe une légère différence dans le nombre d'arbres utilisés, qui passe de 82 à 89, ce qui entraîne une sélection de variables plus étendue avec 116 variables retenues sur les 224.

4.5 Comparaison

Dans cette dernière partie, l'objectif est de comparer nos différentes approches.

Pour commencer, le Tableau 15 permet d'analyser les valeurs d'alpha, de lambda et le nombre de variables sélectionnées pour chaque méthode.

Tableau 15 Comparaison des hyperparamètres

	Sans SIS			Avec SIS		
	α	λ	Variables	α	λ	Variables
Ridge	0	0.3853	224	0	0.2205	119
SCAD	(1)	0.02018	27	(1)	0.02164	44
Elastic N	0.5	0.1519	11	0.5	0.1519	11
EN gs	0.3	0.2205	15	0.3	0.2205	15
EN caret	0.8	0.01963	51	1	0.01353	49
LASSO	1	0.0722	11	1	0.0722	11
aLASSO	(0), (1)	0.2212	6	(0), (1)	0.2110	7

Dans notre première méthode, avec un alpha de 1 pour LASSO, le modèle effectue une sélection stricte en forçant certains coefficients à zéro. Cette approche réduit la complexité en ne conservant que les variables les plus significatives, ce qui conduit à une sélection de 11 variables. À l'opposé, en utilisant un alpha de 0 pour le Ridge, le modèle applique une régularisation sur l'ensemble des coefficients sans supprimer de variables. Cela permet de stabiliser les estimations tout en conservant l'intégralité des 224 variables.

Avec l'approche Elastic Net, par grid search a sélectionné un alpha optimal de 0,3, appliquant une combinaison de 30 % de LASSO et 70 % de RIDGE. Cette pondération, davantage orientée vers RIDGE, limite la suppression de variables et conduit à la sélection de 15 prédicteurs. En revanche, avec caret, l'alpha optimal est de 0,8, ce qui privilégie

davantage LASSO, mais en appliquant une pénalisation moins agressive, ce qui permet de conserver 51 variables. Cette différence illustre que, bien que LASSO tende à forcer certains coefficients à zéro, la configuration caret maintient plus de variables en raison d'un équilibre différent entre régularisation et sélection.

Dans le modèle SCAD, avec un α de 1, seule la pénalité SCAD est appliquée, sans contribution de RIDGE. Cela permet une sélection de 27 variables de manière plus fine, moins biaisée que celle du LASSO. Enfin, pour l'adaptive Lasso (aLASSO), α est d'abord fixé à 0 (RIDGE) pour estimer les poids de manière stabilisante, puis passé à 1 (LASSO) pour une sélection finale basée sur ces poids. Avec un γ de 0,5, l'algorithme module la pénalisation selon l'importance des variables, menant à une sélection très stricte avec seulement 6 variables retenues.

Si l'on compare ces résultats aux résultats obtenus après la sélection SIS Tableau 15 – droite, le changement le plus notable apparaît dans l'approche SCAD, où le λ passe de 0,02018 à 0,02164 avec la présélection par SIS, et le nombre de variables retenues augmente de 27 à 44. Ce résultat montre que SCAD, après la sélection de variables par SIS, identifie plus de prédicteurs comme pertinents. Cette augmentation s'explique par la nature de SCAD, qui pénalise moins fortement les coefficients importants. Ainsi, en travaillant avec un ensemble déjà réduit par SIS, SCAD tend à conserver davantage de variables significatives, même avec une légère hausse de λ .

Dans le cas de RIDGE, bien qu'il n'y ait pas de sélection stricte de variables, le λ optimal passe de 0,3853 sans SIS à 0,2205 avec SIS. Cette diminution est cohérente avec le filtrage initial par SIS, qui réduit la complexité des données, permettant au modèle de fonctionner avec une régularisation moins intense.

Pour récapituler les variables sélectionnées par chaque approche, nous avons synthétisé les prédicteurs stables dans le Tableau 16: ceux qui apparaissent systématiquement dans toutes les méthodes. Cette sélection permet de mettre en lumière les variables les plus robustes pour notre modèle, tout en allégeant la liste de variables figurant en Annexe 7, où sont détaillées toutes les variables retenues par chaque méthode.

Tableau 16 Variables sélectionnées pour toutes les méthodes

CPIH_ALL	CPIH INDEX 00: ALL ITEMS 2015=100, consumer price inflation that includes owner occupiers' housing costs
CPI_EX_ENER	CPI INDEX: Excluding energy (SP) 2015=100
CPI_GOOD	CPI INDEX: Goods 2015=100
CPI_ALL_lag1	Retard 1 variable CPI_ALL
CPI_ALL_lag2	Retard 2 variables CPI_ALL

Les variables sélectionnées par toutes les méthodes montrent une forte cohérence avec l'indice des prix à la consommation. La première, CPIH_ALL, inclut les coûts d'occupation pour les propriétaires, ajoutant ainsi une dimension complète à l'inflation liée à la consommation. Ensuite, CPI_EX_ENER, l'indice des prix hors énergie, fournit une perspective plus stable en éliminant la volatilité des prix de l'énergie, ce qui aide à capter la tendance structurelle de l'inflation.

CPI_GOOD se concentre sur l'évolution des prix des biens, offrant une granularité supplémentaire pour distinguer l'influence des biens de consommation spécifiques.

Enfin, les retards CPI_ALL_lag1 et CPI_ALL_lag2 capturent l'effet de persistance de l'inflation, reliant les niveaux passés de l'indice à ses valeurs futures. Cette autocorrélation traduit l'inertie souvent observée dans la dynamique des prix à la consommation, où les valeurs antérieures constituent des indicateurs importants pour les tendances à venir. Cet ensemble de variables, donc, apparaît cohérent pour modéliser l'inflation.

Il est important de noter que d'autres variables, telles que UNEMP_DURA_24mth, RPI_GOOD, PPI_MANU et CPI_TRANS, apparaissent également avec une fréquence élevée, étant présentes dans presque toutes les approches. Bien que leur inclusion varie légèrement d'un modèle à l'autre, ces variables montrent une stabilité significative dans la modélisation de l'inflation.

La variable UNEMP_DURA_24mth, qui mesure la durée du chômage, capte des dynamiques du marché du travail influençant la consommation et les pressions inflationnistes. RPI_GOOD, l'indice des prix au détail pour les biens, apporte une perspective supplémentaire, souvent sensible aux variations des prix des biens courants.

PPI_MANU, représentant les coûts de production dans le secteur manufacturier, reflète les pressions inflationnistes à travers les coûts des intrants, et CPI_TRANS, qui suit les prix du secteur des transports.

Pour conclure notre dernier tableau nous permet de comparer les coefficients β pour chaque modèle Tableau 17.

Le coefficient bêta représente l'effet estimé d'une variable indépendante sur la variable dépendante dans un modèle de régression.

On peut observer que la variable lag1 donc le premier décalage temporel s'est révélée être l'une des plus influentes, en particulier avec la méthode SCAD, où son coefficient bêta atteint environ 0,325. Les variables CPI_EX_ENER et CPI_GOOD ont également obtenu des coefficients élevés dans plusieurs méthodes, notamment LASSO et EN caret.

Certaines méthodes, comme Elastic Net, EN par grid search et LASSO, montrent des coefficients bêta stables avec et sans SIS.

De plus, après l'application de la méthode SIS, les coefficients des variables clés ont légèrement augmenté, renforçant leur importance dans le modèle. Les variations entre les méthodes indiquent que le choix de la technique de pénalisation influence la sélection et l'impact des variables

Tableau 17 Comparaison des estimations β

	Sans SIS					Avec SIS				
	CPIH_ALL	CPI_EX_ENER	CPI_GOOD	lag1	lag2	CPIH_ALL	CPI_EX_ENER	CPI_GOOD	lag1	lag2
Ridge	0.105	0.124	0.107	0.086	0.083	0.116	0.1365	0.1273	0.1093	0.0920
SCAD	0.149	0.205	0.283	0.325	0.112	0.165	0.2001	0.2479	0.3604	0.1049
Elastic N	0.114	0.197	0.136	0.152	0.136	0.114	0.197	0.136	0.152	0.136
EN gs	0.121	0.180	0.125	0.141	0.128	0.121	0.180	0.125	0.141	0.128
EN caret	0.094	0.242	0.206	0.165	0.122	0.108	0.2380	0.2141	0.1820	0.1187
LASSO	0.071	0.231	0.177	0.165	0.147	0.071	0.231	0.177	0.165	0.147
aLASSO	0.204	0.146	0.033	0.179	0.110	0.204	0.148	0.036	0.179	0.113

5 Conclusion

Dans ce projet, nous avons exploré différentes méthodes d'analyse et de sélection de variables appliquées à notre base de données macroéconomiques, la « United Kingdom Monthly Database ». Cette base, composée de données mensuelles pour le Royaume-Uni, inclut 110 variables explicatives couvrant divers aspects économiques, et nous avons pour variable cible le CPI_ALL, qui représente l'indice des prix à la consommation.

Nous avons commencé par traiter les valeurs manquantes et les outliers. Ensuite nous nous sommes concentrés sur notre variable cible, pour comprendre les transformations qui avaient été appliqués. La stationnarité a été obtenue en appliquant une différenciation logarithmique et une désaisonnalisation.

Par la suite, nous avons analysé les statistiques descriptives, les corrélations, et les distributions des données, pour mieux saisir la structure globale. Enfin, nous avons utilisé des techniques de classification, telles que l'ACP et le clustering hiérarchique, qui nous ont permis d'avoir une vue d'ensemble sur la répartition des données et les relations possibles entre les variables.

Avant de poursuivre, nous avons appliqué des retards aux variables explicatives et ajouté quatre retards à la variable cible, augmentant ainsi notre ensemble à 224 variables explicatives. Initialement, nous avons testé la méthode GETS pour sélectionner les variables, mais cette approche n'a pas abouti à des résultats.

Nous avons ensuite appliqué divers modèles de régression pénalisée (Ridge, LASSO, Elastic Net, SCAD et Adaptive LASSO) sur la base de données complète pour identifier les variables les plus pertinentes, chaque méthode ajustant les coefficients en fonction de leur importance relative dans l'explication de la variable cible. Puis, nous avons utilisé une méthode de réduction de dimension, SIS, pour présélectionner les variables avant de réappliquer ces modèles de régression pénalisée. Sur cet ensemble réduit de 149 variables, nous avons réexaminé les modèles pour observer les effets de la réduction dimensionnelle.

Enfin, nous avons intégré un modèle de gradient boosting pour effectuer une sélection de variables de manière non linéaire. Bien que ce modèle ne repose pas sur des paramètres de pénalisation explicites, nous avons observé que les sélections de variables variaient en fonction des hyperparamètres, tels que la profondeur des arbres et le nombre de nœuds, aboutissant à un ensemble de variables plus étendu que les méthodes de régression pénalisées.

Pour récapituler, nous avons élaboré un tableau comparatif des paramètres et des variables sélectionnées pour chaque méthode, avec et sans SIS. Nous avons constaté une certaine stabilité des méthodes de régression pénalisées, telles que Lasso et Elastic Net, même après la réduction par SIS. Cette stabilité peut être attribuée en partie à leur structure de pénalisation, qui favorise la sélection de variables fortement corrélées avec la cible et particulièrement informatives pour le modèle. Elastic Net, en combinant les approches Lasso et Ridge, assure également une gestion équilibrée de la multicolinéarité, ce qui explique en partie pourquoi la réduction par SIS n'a pas entraîné de changement majeur dans les variables sélectionnées.

En revanche, SCAD, en raison de sa pénalité concave, adopte une approche plus flexible en relâchant la pénalisation pour les coefficients importants. Cette méthode est particulièrement avantageuse lorsque des variables corrélées mais informatives subsistent dans l'ensemble réduit par SIS, car elle conserve davantage de variables sans biaiser excessivement les coefficients importants.

En conclusion, chaque méthode présente des spécificités uniques, rendant leur comparaison complexe. La prochaine étape pour déterminer la méthode la plus performante consisterait à évaluer leurs performances prédictives sur un jeu de données divisé en train et test, ce qui offrirait un aperçu de la qualité des prévisions et de la pertinence de chaque méthode dans le contexte de notre base de données.

6 Bibliographie

ARBRES DE DECISION et MÉTHODES D'ENSEMBLES (Random Forests, gradient boosting)
(E. Vigneau, pag 77 10 2024).

Consumer price inflation, UK: October 2022. (2022, 11 16). Récupéré sur Office for National
Statistics:

<https://www.ons.gov.uk/economy/inflationandpriceindices/bulletins/consumer-priceinflation/october2022>

Goulet Coulombe, P. M. (2021). Can Machine Learning Catch the COVID-19 Recession ?
National Institute Economic Review, 256, 71-109. doi: 10.1017/nie.2021.10.

James Honaker, G. K. (2023, 04). *Package 'Amelia'*. Récupéré sur CRAN: <https://cran.r-project.org/web/packages/Amelia/Amelia.pdf>


Machine Learning, Régressions Pénalisées et Sélection de Variables, pag 19 (O. Darné 10
2024).

Techniques de Prévision et Conjoncture , Chap 3: Méthode GETS et package R, pag 68 (O.
Darné 02 2024).


7 Annexe

Analyse série brute, fichier « raw_uk_md »


Annexe 1 Graphique série CPI ALL données brutes




Annexe 2 Série avec différenciation du logarithme




Annexe 3 ACP - coude



Annexe 4 Contribution des variables par axe




Annexe 5 Corrélations négatives avec CPI ALL




Montre comment les coefficients changent pour différentes valeurs de lambda, selon la méthode :


- Lasso




- Ridge




- Elastic Net, alpha 0,5




- Grid search alpha 0.3



- SCAD



- aLASSO



Annexe 7 Récapitulatif des variables sélectionnées par chaque méthodes (sans l'approche SIS)

LASSO	Elastic Net			SCAD	aLASSO
UNEMP_DURA_24mth	UNEMP_DURA_24m	UNEMP_DURA_24	EMP_PART	UNEMP_DURA_24mth	CPIH_ALL
CPIH_ALL	CPIH_ALL	CPIH_ALL	UNEMP_RATE	AWE_PRIV	CPI_EX_ENER
CPI_EX_ENER	CPI_EX_ENER	CPI_EX_ENER	UNEMP_DURA_6.12mth	AVG_WEEK_RETAIL_SA	CPI_GOOD
CPI_GOOD	CPI_GOOD	CPI_GOOD	UNEMP_DURA_12mth	LE	RPI_GOOD
CPI_TRANS	CPI_TRANS	CPI_TRANS	UNEMP_DURA_24mth	CPIH_ALL	CPI_ALL_lag1
RPI_GOOD	RPI_GOOD	RPI_GOOD	CLAIMS	CPI_EX_ENER	CPI_ALL_lag2
PPI_MANU	PPI_MANU	PPI_MANU	AWE_PRIV	CPI_GOOD	
CPI_ALL_lag1	CPI_ALL_lag1	CPI_ALL_lag1	IOP_OIL_EXTRACT	CPI_TRANS	
CPI_ALL_lag2	CPI_ALL_lag2	CPI_ALL_lag2	IOS_EDUC	RPI_SERV	
CPI_ALL_lag3	CPI_ALL_lag3	CPI_ALL_lag3	CAR_REGIS	EXP_GOOD	
CPI_ALL_lag4	CPI_ALL_lag4	CPI_ALL_lag4	AVG_WEEK_RETAIL_SAL	EXP_MACH	
		CPI_DUR	E_NON_FOOD	MORT_FIXED_RATE_5Y	
		CPI_NON_DUR	CPIH_ALL	RS	
		PPI_MANU_lag1	CPI_EX_ENER	M1	
		PPI_MACH_lag1	CPI_GOOD	PPI_MOTOR	
			CPI_DUR	EMP_ACT_lag1	
			CPI_NON_DUR	AWE_PUB_lag1	
			CPI_TRANS	VAC_MANU_lag1	
			RPI_GOOD	IOP_MINE_lag1	
			RPI_SERV	IOP_PETRO_lag1	
			IMP_ALL	CPI_EX_ENER_lag1	
			EXP_MACH	CPI_TRANS_lag1	
				EXP_MACH_lag1	

CONS_CREDIT_ex_stude	IMP_METAL_lag1
nt_loan	PPI_MACH_lag1
MORT_FIXED_RATE_5YR	PPI_METAL_lag1
S	CPI_ALL_lag1
M1	CPI_ALL_lag2
EUR_UNC_INDEX	CPI_ALL_lag4
CCI	
PPI_MANU	
PPI_MACH	
PPI_MOTOR	
UNEMP_DURA_6mth_lag	
1	
EMP_ACT_RATE_lag1	
AWE_PUB_lag1	
VAC_TOT_lag1	
VAC_MANU_lag1	
IOP_MINE_lag1	
IOP_PETRO_lag1	
CPI_TRANS_lag1	
EXP_MACH_lag1	
IMP_METAL_lag1	
GBP_CAN_lag1	
CONS_CREDIT_ex_stude	
nt_loan_lag1	
MORT_FIXED_RATE_5YR	
S_lag1	
M1_lag1	
BGS_5yrs_yld_lag1	
PPI_MANU_lag1	
PPI_MACH_lag1	
PPI_METAL_lag1	
CPI_ALL_lag1	
CPI_ALL_lag2	
CPI_ALL_lag3	
CPI_ALL_lag4	

Annexe 8 Variables sélectionnées par SIS

Au total 149 variables on était sélectionnées


EMP_PART, UNEMP_RATE, UNEMP_DURA_12mth., UNEMP_DURA_24mth., CLAIMS, CLAIMS_RATE, TOT_WEEK_HRS, AVG_WEEK_HRS, AVG_WEEK_HRS_FULL, AWE_ALL, AWE_CONS, AWE_MANU, AWE_PRIV, VAC_TOT, VAC_CONS, VAC_MANU, IOP_CAP_GOOD, IOP_ENER, IOP_PETRO, IOS, IOS_45, IOS_G, IOS_EDUC, IOS_PNDS, RSI, CAR_REGIS, RETAIL_TRADE_INDEX, AVG_WEEK_RETAIL_SALE, AVG_WEEK_RETAIL_SALE_NON_FOOD, CPIH_ALL, CPI_EX_ENER, CPI_GOOD, CPI_DUR, CPI_NON_DUR, CPI_SERV, CPI_CLOTH, CPI_TRANS, RPI_ALL, RPI_GOOD, RPI_SERV, RPI_HOUSE, EXP_FUEL, IMP_OIL, IMP_MACH, GBP_CAN, GBP_JAP, OIL_PRICE, BANK_RATE, CONS_CREDIT_ex_student_loan, MORT_FIXED_RATE_5YRS, MORT_FIXED_RATE_2YRS, M1, M2, M3, M4, LIBOR_3mth, SONIA, BGS_5yrs_yld,

BGS_10yrs_yld, BGS_20yrs_yld, FTSE250, CCI, PPI_MANU, PPI_MACH, PPI_OIL, PPI_METAL, PPI_MOTOR, EMP_PART_lag1, UNEMP_DURA_12mth_lag1, UNEMP_DURA_24mth_lag1, EMP_RATE_lag1, CLAIMS_lag1, CLAIMS_RATE_lag1, TOT_WEEK_HRS_lag1, AVG_WEEK_HRS_lag1, AVG_WEEK_HRS_FULL_lag1, AWE_ALL_lag1, AWE_CONS_lag1, AWE_MANU_lag1, AWE_PRIV_lag1, AWE_SERV_lag1, VAC_TOT_lag1, VAC_CONS_lag1, VAC_MANU_lag1, IOP_CAP_GOOD_lag1, IOP_ENER_lag1, IOP_MINE_lag1, IOP_PETRO_lag1, IOP_OIL_EXTRACT_lag1, IOS_lag1, IOS_45_lag1, IOS_46_lag1, IOS_47_lag1, IOS_G_lag1, IOS_EDUC_lag1, IOS_PNDS_lag1, AVG_WEEK_RETAIL_SALE_lag1, AVG_WEEK_RETAIL_SALE_NON_FOOD_lag1, CPIH_ALL_lag1, CPI_EX_ENER_lag1, CPI_GOOD_lag1, CPI_DUR_lag1, CPI_NON_DUR_lag1, CPI_SERV_lag1, CPI_CLOTH_lag1, CPI_TRANS_lag1, RPI_ALL_lag1, RPI_GOOD_lag1, RPI_SERV_lag1, RPI_HOUSE_lag1, EXP_TOT_lag1, EXP_GOOD_lag1, IMP_ALL_lag1, EXP_FUEL_lag1, EXP_OIL_lag1, EXP_MACH_lag1, EXP_CRUDE_MAT_lag1, GBP_CAN_lag1, GBP_JAP_lag1, GBP_US_lag1, OIL_PRICE_lag1, BANK_RATE_lag1, CONS_CREDIT_ex_student_loan_lag1, MORT_FIXED_RATE_5YRS_lag1, MORT_FIXED_RATE_2YRS_lag1, M1_lag1, M2_lag1, M3_lag1, M4_lag1, LIBOR_3mth_lag1, SONIA_lag1, BGS_5yrs_yld_lag1, BGS_10yrs_yld_lag1, BGS_20yrs_yld_lag1, FTSE_ALL_lag1, SP500_lag1, UK_focused_equity_lag1, BCI_lag1, CCI_lag1, CLI_lag1, PPI_MANU_lag1, PPI_MACH_lag1, PPI_OIL_lag1, PPI_METAL_lag1, PPI_MOTOR_lag1, CPI_ALL_lag1, CPI_ALL_lag2, CPI_ALL_lag3, CPI_ALL_lag4


Annexe 9 Résultats méthode GETS - avec SIS

UNEMP_RATE	AVG_WEEK_RETAIL_SALE_lag1	CPIH_ALL
UNEMP_DURA_24mth.	CPI_EX_ENER_lag1	CPI_EX_ENER
CLAIMS	RPI_ALL_lag1	CPI_GOOD
AVG_WEEK_HRS_FULL	RPI_SERV_lag1	CPI_SERV
VAC_TOT	RPI_HOUSE_lag1	CPI_TRANS
IOP_CAP_GOOD	EXP_MACH_lag1	RPI_ALL
IOS_45	EXP_CRUDE_MAT_lag1	RPI_GOOD
IOS_G	GBP_CAN_lag1	MORT_FIXED_RATE_5YRS
IOS_EDUC	BGS_5yrs_yld_lag1	MORT_FIXED_RATE_2YRS
RSI	BGS_20yrs_yld_lag1	M1
AVG_WEEK_RETAIL_SALE	CCI_lag1	LIBOR_3mth
AVG_WEEK_RETAIL_SALE_NON_FOOD	CLI_lag1	PPI_MANU
IOS_45_lag1	PPI_MACH_lag1	PPI_OIL
IOS_46_lag1	PPI_METAL_lag1	PPI_METAL
IOS_G_lag1	UNEMP_DURA_12mth_lag1	CPI_ALL_lag1
IOS_EDUC_lag1		CPI_ALL_lag2
IOS_PNDS_lag1		CPI_ALL_lag4


- SCAD




- LASSO




- Elastic Net , alpha 0.5



- RIDGE



- aLASSO




Annexe 11 Variables sélectionnés par méthodes avec SIS

LASSO	Elastic Net			SCAD	aLASSO
UNEMP_DURA_24	UNEMP_DURA_24	UNEMP_DURA_24	EMP_PART	UNEMP_RATE	CPIH_ALL
meth.	meth	meth	UNEMP_RATE	UNEMP_DURA_24meth.	CPI_EX_ENER
CPIH_ALL	CPIH_ALL	CPIH_ALL	UNEMP_DURA_24meth.	CLAIMS	CPI_GOOD
CPI_EX_ENER	CPI_EX_ENER	CPI_EX_ENER	CLAIMS	AVG_WEEK_HRS_FULL	RPI_GOOD
CPI_GOOD	CPI_GOOD	CPI_GOOD	AVG_WEEK_HRS_FULL	AWE_PRIV	CPI_ALL_lag1
CPI_TRANS	CPI_TRANS	CPI_TRANS	AWE_MANU	VAC_TOT	CPI_ALL_lag2
RPI_GOOD	RPI_GOOD	RPI_GOOD	AWE_PRIV	IOP_CAP_GOOD	CPI_ALL_lag4
PPI_MANU	PPI_MANU	PPI_MANU	IOS_45	IOP_ENER	
CPI_ALL_lag1	CPI_ALL_lag1	CPI_ALL_lag1	IOS_EDUC	IOS_EDUC	
CPI_ALL_lag2	CPI_ALL_lag2	CPI_ALL_lag2	CAR_REGIS	RSI	
CPI_ALL_lag3	CPI_ALL_lag3	CPI_ALL_lag3	AVG_WEEK_RETAIL_S	CAR_REGIS	
CPI_ALL_lag4	CPI_ALL_lag4	CPI_ALL_lag4	ALE_NON_FOOD	AVG_WEEK_RETAIL_SA	
		CPI_DUR	CPIH_ALL	LE	
		CPI_NON_DUR	CPI_EX_ENER	CPIH_ALL	
		PPI_MANU_lag1	CPI_GOOD	CPI_EX_ENER	
		PPI_MACH_lag1	CPI_DUR	CPI_GOOD	
			CPI_NON_DUR	CPI_TRANS	
			CPI_TRANS	RPI_SERV	
			RPI_GOOD	MORT_FIXED_RATE_5Y	
			RPI_SERV	RS	
			CONS_CREDIT_ex_stud	M1	
			ent_loan	FTSE250	
			MORT_FIXED_RATE_5	PPI_MANU	
			YRS	PPI_OIL	
			M1	PPI_METAL	
			CCI	PPI_MOTOR	
			PPI_MANU	UNEMP_DURA_12meth._	
			PPI_MACH	lag1	
			PPI_MOTOR	TOT_WEEK_HRS_lag1	
			VAC_TOT_lag1	VAC_TOT_lag1	
			VAC_MANU_lag1	IOP_MINE_lag1	
			IOP_ENER_lag1	IOP_PETRO_lag1	
			IOP_MINE_lag1	IOS_45_lag1	
			IOP_PETRO_lag1	CPI_EX_ENER_lag1	
			CPI_EX_ENER_lag1	CPI_SERV_lag1	
			CPI_DUR_lag1	CPI_TRANS_lag1	

CPI_TRANS_lag1	EXP_MACH_lag1
EXP_MACH_lag1	EXP_CRUDE_MAT_lag1
GBP_CAN_lag1	GBP_CAN_lag1
CONS_CREDIT_ex_stud	GBP_JAP_lag1
ent_loan_lag1	M1_lag1
MORT_FIXED_RATE_5	BGS_5yrs_yld_lag1
YRS_lag1	BCI_lag1
M1_lag1	PPI_MACH_lag1
BGS_5yrs_yld_lag1	CPI_ALL_lag1
PPI_MANU_lag1	CPI_ALL_lag2
PPI_MACH_lag1	CPI_ALL_lag4
PPI_METAL_lag1	
CPI_ALL_lag1	
CPI_ALL_lag2	
CPI_ALL_lag3	
CPI_ALL_lag4	

Annexe 12 Choix des paramètres Gradient boosting



Annexe 13 Variables sélectionnées par le Gradient boosting

CPIH_ALL	UK_focused_equity_lag1	IOS_47_lag1
CPI_EX_ENER	EMP_PART_lag1	IOP_PETRO
CPI_ALL_lag1	VAC_TOT	CPI_GOOD_lag1
RPI_ALL	CCI_lag1	PPI_MACH_lag1
CPI_GOOD	M4_lag1	CONS_CREDIT_ex_student_loan_lag1
CPI_ALL_lag2	CPI_SERV_lag1	UNEMP_DURA_24mth.
CPI_TRANS	CPI_DUR	IOS_G
PPI_MANU	EXP_MACH_lag1	BGS_20yrs_yld_lag1
CPI_ALL_lag4	BGS_10yrs_yld	CPI_TRANS_lag1
RPI_ALL_lag1	AWE_MANU	PPI_METAL_lag1
CPI_CLOTH_lag1	CPI_NON_DUR_lag1	CLAIMS
PPI_MANU_lag1	BANK_RATE	IOP_ENER_lag1
CPI_ALL_lag3	IOP_MINE_lag1	PPI_MACH

CONS_CREDIT_ex_student_loan	M2_lag1	AVG_WEEK_RETAIL_SALE
CPI_CLOTH	IOS_G_lag1	AWE_SERV_lag1
RPI_SERV	AVG_WEEK_HRS	IMP_MACH
CLI_lag1	TOT_WEEK_HRS_lag1	AWE_MANU_lag1
CPI_NON_DUR	PPI_METAL	BGS_20yrs_yld
EXP_TOT_lag1	IOS_PNDS	AWE_PRIV_lag1
CLAIMS_lag1	UNEMP_DURA_12mth.	MORT_FIXED_RATE_5YRS_lag1
CLAIMS_RATE	IOS_45_lag1	UNEMP_RATE
CPI_SERV	AVG_WEEK_RETAIL_SALE_lag1	AVG_WEEK_HRS_lag1
GBP_CAN_lag1	BGS_5yrs_yld	AWE_CONS_lag1
MORT_FIXED_RATE_2YRS_lag1	AWE_CONS	AVG_WEEK_RETAIL_SALE_NON_FOOD
EXP_CRUDE_MAT_lag1	IOP_CAP_GOOD	IOP_PETRO_lag1
OIL_PRICE	GBP_JAP	IOP_CAP_GOOD_lag1
PPI_MOTOR	EMP_PART	EXP_FUEL
IOS_PNDS_lag1	IOS_45	BGS_5yrs_yld_lag1
TOT_WEEK_HRS	FTSE_ALL_lag1	AWE_PRIV
	MORT_FIXED_RATE_2YRS	OIL_PRICE_lag1

Annexe 14 Variables sélectionnées Gradient boosting sans SIS

CLAIMS_RATE	CPIH_ALL	IOP_ENER_lag1
CPI_NON_DUR	CPI_EX_ENER	OIL_PRICE
CLI_lag1	CPI_ALL_lag1	UNEMP_DURA_24mth.
UNEMP_DURA_6.12mth_lag1	RPI_ALL	CPI_TRANS_lag1
CLAIMS_lag1	CPI_GOOD	PPI_METAL_lag1
MORT_FIXED_RATE_2YRS_lag1	CPI_ALL_lag2	IOP_CAP_GOOD_lag1
FTSE250_lag1	PPI_MANU	AVG_WEEK_RETAIL_SALE_NON_FOOD
EXP_TOT_lag1	CPI_TRANS	PPI_MACH
IMP_MACH	CPI_ALL_lag4	CPI_GOOD_lag1
EMP_TEMP	RPI_ALL_lag1	BGS_20yrs_yld_lag1
GBP_US_lag1	CPI_CLOTH_lag1	EMP_RATE
GBP_CAN_lag1	PPI_MANU_lag1	IMP_OIL
UNEMP_DURA_6mth_lag1	CPI_ALL_lag3	PPI_MACH_lag1
IOS_G	CPI_CLOTH	CCI
EXP_CRUDE_MAT_lag1	CPI_SERV	CPIH_ALL_lag1
IOS_47_lag1	CONS_CREDIT_ex_student_loan	CONS_CREDIT_ex_student_loan_lag1
UNEMP_DURA_12mth.	RPI_SERV	IOP_PROD_lag1
EXP_METAL_lag1	IOS_G_lag1	AWE_PUB
M2_lag1	AWE_ALL	IOS_PNDS_lag1
IOS_47	GBP_BROAD_lag1	EUR_UNC_INDEX_lag1
PPI_MOTOR	EMP_TEMP_lag1	IOP_PETRO
OIL_PRICE_lag1	AWE_MANU_lag1	AVG_WEEK_HRS_lag1
MORT_FIXED_RATE_2YRS	IOS_PNDS	AWE_PRIV
IOP_INT_GOOD	EXP_METAL	IOP_GOOD_lag1
IOP_MANU_lag1	IMP_CRUDE_MAT	TOT_LENDING_APP_lag1
TOT_WEEK_HRS	UNEMP_DURA_6mth	TOT_HOUSE_APP_lag1
BGS_10yrs_yld	IOS_45_lag1	EMP

CLI	BGS_20yrs_yld	IOP_PETRO_lag1
IOP_MINE_lag1	GBP_BROAD	IOP_GOOD
AWE_MANU	AVG_WEEK_RETAIL_SALE	AWE_PUB_lag1
EXP_GOOD_lag1	IOP_MACH_lag1	IMP_METAL
SONIA_lag1	AVG_WEEK_RETAIL_SALE_lag1	IMP_GOOD_lag1
SONIA	IOP_OIL_EXTRACT	EXP_MACH
IMP_ALL	IOP_PROD	EMP_PART
SP500	IOS_45	RPI_HOUSE_lag1
EMP_ACT_RATE_lag1	FTSE_ALL	EMP_PART_lag1
CPI_DUR	EXP_OIL	IOP_ENER
AWE_CONS	PPI_MOTOR_lag1	CLAIMS
CPI_NON_DUR_lag1		UNEMP_DURA_6.12mth

Libraries

Amelia : Traitement des données manquantes par imputation multiple
amap : Analyse de regroupement et méthodes d'analyse en composantes principales
corrplot : Visualisation des matrices de corrélation
ClustOfVar : Regroupement des variables
cluster : Fonctions pour l'analyse de regroupement (clustering)
dplyr : Manipulation et transformation de données
doParallel : Traitement parallèle pour exécuter des opérations en parallèle
FactoMineR : Analyse multivariée des données (ACP, ACM, AFC, etc.)
factoextra : Visualisation et extraction des résultats d'analyses multivariées
gbm : Modélisation
gets : Modélisation du général au spécifique
glmnet : Régressions pénalisées (LASSO, Ridge, Elastic Net)
ggplot2 : Visualisation
lmtest : Tests de diagnostic pour les modèles linéaires
ncvreg : Régressions pénalisées avec SCAD et MCP
NbClust : Détermination du nombre optimal de clusters
tidyverse :
tseries : Analyse de séries temporelles et applications en finance
tsoutliers : Détection des valeurs aberrantes dans les séries temporelles
seasonal : Ajustement saisonnier des séries temporelles avec X-13ARIMA-SEATS
SIS : Sélection de variables par criblage indépendant (Sure Independence Screening)
reshape2 : Réorganisation et transformation des données
JLutils : package depuis GitHub

Liste des figures et tableaux

Figure 1 Outliers série à niveau CPI-ALL	3
Figure 2 Comparaison série en niveau et série ajustée	4
Figure 3 Graphique de la série à expliquer	5
Figure 4 Distribution série ajusté	7
Figure 5 ACP	8
Figure 6 Clustering hiérarchique – Dendrogramme avec clusters	10
Figure 7 Corrélacion cluster 1 et 2.....	12
Figure 8 Corrélacion cluster 3.....	13
Figure 9 Corrélacions positives avec CPI ALL	15
Figure 10 Nombre d'arbres optimal	28
Tableau 1 Détaille des points atypiques.....	3
Tableau 2 Statistiques descriptives.....	6
Tableau 3 Shapiro-Wilk normality test.....	7
Tableau 4 Résultat méthode LASSO	17
Tableau 5 Résultat méthode Ridge	18
Tableau 6 Résultat méthode Elastic Net.....	20
Tableau 7 Résultat méthode SCAD	21
Tableau 8 Résultat méthode aLASSO	22
Tableau 9 Résultat SCAD avec SIS	25
Tableau 10 Résultat méthode LASSO avec SIS.....	25
Tableau 11 Résultats méthodes Elastic Net avec SIS	26
Tableau 12 Résultat méthode RIDGE avec SIS.....	26
Tableau 13 Résultats méthodes aLASSO avec SIS	27
Tableau 14 Paramètres choisis Gradient boosting avec SIS.....	28
Tableau 15 Comparacion des hyperparamètres.....	29
Tableau 16 Variables sélectionnées pour toutes les méthodes.....	31
Tableau 17 Comparacion des estimations β	33

Table des matières

1	SOMMAIRE	4
2	INTRODUCTION	1
3	ANALYSE EXPLORATOIRE ET DESCRIPTIVE	2
3.1	ANALYSE DES VALEURS MANQUANTES	2
3.2	ANALYSE DES OUTLIERS : DETECTION ET CORRECTION	3
3.3	ANALYSE DE LA STATIONNARITÉ DE LA VARIABLE À EXPLIQUER	4
3.4	GRAPHIQUE DE LA VARIABLE À EXPLIQUER EN NIVEAU	5
3.5	STATISTIQUES DESCRIPTIVES DE LA VARIABLE À EXPLIQUER	6
3.6	CLASSIFICATION	7
3.7	CORRELATION ENTRE VARIABLES EXPLICATIVES	11
		12
3.8	CORRELATION ENTRE LES VARIABLES EXPLICATIVE ET LA VARIABLE À EXPLIQUER	14
4	SELECTION DES VARIABLES	16
4.1	APPROCHE ECONOMETRIQUE : GETS	16
4.2	REGRESSIONS PENALISEES : RIDGE, LASSO, ELASTIC-NET, SCAD ET ADAPTIVE LASSO	17
4.2.1	Lasso	17
4.2.2	Ridge	18
4.2.3	Elastic Net	19
4.2.4	SCAD	21
4.2.5	Adaptive Lasso	22
4.3	APPROCHE DE REDUCTION DE DIMENSION	23
4.3.1	GETS	23
4.3.2	Régressions pénalisées - SCAD	24
4.3.3	LASSO	25
4.3.4	Elastic Net	26
4.3.5	RIDGE	26
4.3.6	aLASSO	27
4.4	METHODE NON LINEAIRE – GRADIENT BOOSTING	27
4.5	COMPARAISON	29
5	CONCLUSION	34
6	BIBLIOGRAPHIE	36
7	ANNEXE	37